

Análise de Imagem para Contagem Automática de Células

Filipa Pato (up202106484), Leandro Ribeiro (up202105358), Leonor Franco (up202005374),

Maria Rocha (up202105699), V. Sofia Sousa (up202107418)

I. RESUMO

O presente trabalho pretende aplicar diversas técnicas de análise de imagem num conjunto de imagens obtidas por microscopia, tendo como objetivos a delimitação de uma região de interesse (ROI) e a contagem das células presentes nela (segmentação). Para ambas estas tarefas, foram implementados vários métodos cuja eficácia foi estudada quer por observação direta dos resultados, quer pelo cálculo de métricas de desempenho. Os resultados revelaram-se satisfatórios, com o índice de Jaccard médio de 0.991 para a técnica que melhor funcionou na elaboração da ROI, e o melhor valor médio de Precisão obtido para o *testset* foi de 0,912.

Palavras-Chave: região de interesse, segmentação, métricas, índice de Jaccard, F-measure

II. INTRODUÇÃO

O número de células presentes numa cultura pode fornecer informações relevantes sobre a densidade celular, permitindo monitorizar o crescimento e viabilidade das mesmas. Normalmente, a contagem de células pode ser feita manualmente, mas a fiabilidade dos resultados daí obtidos depende muito da experiência e concentração do examinador. Assim, a contagem automatizada de células baseada em análise de imagem e métodos de visão computacional é uma ferramenta essencial para melhorar a precisão do processo e facilitar o trabalho dos investigadores.

O presente relatório apresenta uma proposta de análise de imagem para a contagem automática de células humanas de leucemia promielocítica (HL60). Inicialmente, o método envolve a delimitação de uma região de interesse onde se encontram as células a serem contadas. Na fase subsequente, realiza-se o pré-processamento da imagem, comparando os resultados obtidos por dois métodos distintos, e, finalmente, são criadas *bounding boxes* para segmentar as células identificadas na imagem processada pelo algoritmo.

III. METODOLOGIA

1. Task 1

A) Line detection

Para a delimitação da região de interesse, foi utilizada a Transformada de Hough para a deteção de linhas. Primeiramente, procedeu-se ao pré-processamento da imagem, constituído na aplicação de um *bottom hat*, seguido de *thresholding*. Deste modo, foi possível detetar as quatro linhas

mais proeminentes da imagem, no caso, as linhas limitantes da região de interesse. Esta técnica indica as linhas correspondentes aos picos da matriz de acumulação do espaço de Hough, ou seja, as linhas que apresentam maior número de pontos. De modo a obter a máscara binária da região de interesse, preencheu-se o interior das quatro linhas. O resultado é uma imagem binária, apresentando o valor lógico verdadeiro no retângulo da região de interesse e falso fora do mesmo.

B) Filtros morfológicos binários

Uma abordagem mais simples para a obtenção da região de interesse consistiu na utilização de uma filtragem espacial não-linear, mais propriamente filtros morfológicos binários, resultantes da implementação de conceitos de morfologia matemática, isto pois estes são capazes de simplificar uma imagem mantendo as principais características da forma dos seus objetos. Sendo assim, após a binarização da imagem, procedeu-se à aplicação de um filtro de *closing*, ou seja, à realização de uma dilatação seguida de uma erosão com o intuito de fechar pequenos buracos, neste caso as regiões entre as 3 linhas que definem a região de contagem. De seguida, de forma que a região de interesse corresponda à linha do meio da imagem original, efetuou-se uma erosão seguida do preenchimento do interior. Finalmente, utilizou-se um filtro de *opening* para remover as pequenas linhas dos cantos e obteve-se a região de interesse final.

C) Métricas de avaliação

No sentido de avaliar a eficácia do algoritmo desenvolvido, calcularam-se as diferentes métricas de desempenho, que permitem estabelecer uma relação entre os resultados obtidos e os *ground truth* correspondentes

Neste sentido, foram determinados o índice de Jaccard e a distância Euclidiana média e máxima entre os vértices das duas máscaras. O índice de Jaccard indica a razão entre a interseção e a união entre as duas regiões, sendo que quanto maior o índice, mais próximas são as imagens. A distância Euclidiana entre os vértices será tanto maior quanto mais diferentes forem as figuras a comparar.

2. Task 2

A) Circle detection

Para reconhecer as células, foi usado o método da transformada de Hough no âmbito da *circle detection*, baseado na criação de um *Hough space* tridimensional (*accumulator array* 3D) a partir da imagem, no espaço xy. Cada célula do *Hough space* corresponde a um conjunto (raio, x_c, y_c), logo, a um círculo e cada pixel vota em todos os possíveis círculos que por ele podem passar. No final, as células no espaço que sejam

picos de intensidade correspondem aos círculos existentes na imagem.

Para aplicar este algoritmo foi necessário processar as imagens de modo a reduzir o ruído e intensificar a definição das bordas, em vista a melhorar a precisão. Como tal, as imagens foram tratadas por dois processos distintos: filtros morfológicos e *clustering*.

i) Filtros morfológicos

Esta abordagem tem em conta a consistência da morfologia matemática aquando da simplificação da imagem, neste caso a forma circular. Assim, foi aplicado o filtro *bottom hat*, que consiste em, primeiro, efetuar um *closing* da imagem (uma dilatação, que expande áreas claras, seguida de uma erosão, que afina áreas claras, permitindo remover pequenos pontos escuros ou *gaps* em zonas claras) e depois calcular a diferença entre este resultado e a imagem original, obtendo uma imagem com os *highlights* escuros destacados. Posteriormente, efetuou-se um *multilevel thresholding*, segmentando a imagem em diferentes intensidades; de seguida efetua-se *binary threshold*, isto é, cria-se uma imagem binária baseada em pixels referentes às duas intensidades mais baixas; por fim, inverte-se esta imagem binária.

ii) Clustering

Primeiramente, foi aplicado um filtro *bottom hat*, efetuando-se seguidamente *k-means clustering* com 3 *clusters*. O método consiste em criar, neste caso, 3 centroides, comparar a distância de cada ponto ao centroide e associá-lo ao que lhe está mais perto, calcular um novo centroide com base na média com os pontos que lhe foram acrescentados e repetir até que o novo centroide não difira significativamente do anterior. Por fim, foi atribuída uma cor de *overlay* a cada cluster, depois colocada em tons de cinzento e depois obtida a imagem binária.

B) Bounding Box

De forma a projetar as *bounding boxes*, fizemos uso das coordenadas dos cantos que irão integrar as mesmas, partindo dos raios e centros das células detetadas, e da largura e altura das mesmas. Para que não fossem evidenciadas as células que se sobrepõem à zona exterior da ROI, nos seus limites inferior e direito, considerou-se o canto inferior direito. Se este fosse de intensidade preto, zona exterior à ROI, ou excedesse os limites da imagem então a célula à qual este pertence não seria considerada para a contagem.

C) Métricas de avaliação

Para a análise de desempenho, retiraram-se os números de células detetadas, verdadeiras positivas, falsas positivas e falsas negativas. A partir destes, obteve-se a sensibilidade, a precisão e a *F-measure*. Para definir quais células foram detetadas corretamente, considerou-se que o índice de *Jaccard* entre as correspondentes *bounding boxes*, a elaborada pelo algoritmo e a *ground truth*, teria de ser maior que 0,5. Tanto a sensibilidade como a precisão correspondem à percentagem de células que foram corretamente segmentadas, sendo que para a primeira se

usa como referência o total de células no GT, enquanto para a segunda se usa o total de células detetadas. Já a *F-measure* combina estas duas grandezas, neste caso com igual contribuição, pois foi utilizado $\beta=1$.

IV. RESULTADOS E DISCUSSÃO

1. Task 1, Trainset

Tabela (1): Resultados métricas ROI para o trainset (Índice de Jaccard e Distância Euclidiana)

	Índice de Jaccard	Distância Euclidiana
Line detection (Média ± Desvio padrão)	0,941 ± 0,043	23,765 ± 19,834
Line detection (Máximo)	0,974	109,640
Filtros morfológicos binários (Média ± Desvio padrão)	0,973 ± 0,048	11,077 ± 21,464
Filtros morfológicos binários (Máximo)	0,996	91,444

Nota: Não é possível aferir acerca da distância Euclidiana, uma vez que esta métrica não está normalizada para uma gama de valores, como o índice de *Jaccard* (entre 0 e 1). Apresentamos então considerações sobre a comparação do desempenho dos dois métodos, aquando da avaliação com esta métrica.

A) Filtros morfológicos binários

Por análise da Tabela (1), entendemos que o índice de *Jaccard* e distância Euclidiana médios, para as ROI obtidas pelos filtros morfológicos binários, assumiram valores de $0,9732 \pm 0,0484$ e $11,077 \pm 21,464$, respetivamente. Os valores máximos foram de 0,9959 e 91,444. Assim, concluímos que as máscaras binárias, experimental e GT, são notavelmente similares, aproximando-se o índice de *Jaccard* da unidade.

B) Comparação dos métodos de obtenção da ROI

Comparando a distância Euclidiana associada aos dois métodos, compreendemos que esta é consideravelmente superior para a ROI obtida com a Transformada de *Hough*. Uma vez que esta representa a distância entre os vértices da GT ROI e máscara experimental, concluímos que o método dos filtros morfológicos demonstra melhor performance, aferindo sobre esta métrica. Ademais, o índice de *Jaccard* para uma ROI conseguida com filtros morfológicos é mais elevado, demonstrando similaridade superior entre os resultados teóricos e experimentais. Tal poderá acontecer uma vez que o método da transformada de *Hough* não deteta sistematicamente as linhas do meio, que constituem a ROI ideal. Desta forma, depreendemos que os filtros morfológicos atingem um melhor desempenho na delineação da mesma, aquando da utilização do conjunto de treino.

2. Task 1, Testset

Tabela (2): Resultados métricas ROI para o testset (Índice de Jaccard e Distância Euclidiana)

	Índice de Jaccard	Distância Euclidiana
Line detection (Média ± Desvio padrão)	0,956 ± 0,067	16,746 ± 27,862
Line detection (Máximo)	0,968	27,586
Filtros morfológicos binários (Média ± Desvio padrão)	0,991 ± 0,002	3,241 ± 0,860
Filtros morfológicos binários (Máximo)	0,995	7,616

A) Line detection

Aferindo acerca do conjunto de teste, pela avaliação da Tabela (2), concluímos que o índice de Jaccard e distância Euclidiana médios, para as ROI obtidas pela Transformada de Hough, assumiram valores de $0,9560 \pm 0,0067$ e $16,746 \pm 27,862$, respetivamente. Os valores máximos foram de 0,9685 e 27,586.

B) Filtros morfológicos binários

Para as ROI obtidas para os filtros binários, o índice de Jaccard e distância Euclidiana médios, exibidos na Tabela (2) foram de $0,9914 \pm 0,0022$ e $3,241 \pm 0,860$, respetivamente. Os valores máximos foram de 0,9953 e 7,6158.

C) Comparação dos métodos de obtenção da ROI

O desempenho dos algoritmos desenvolvidos, aquando da deteção da ROI no conjunto de teste, está em concordância com os resultados anteriores, onde os filtros morfológicos são mais eficientes quando comparados com a Transformada de Hough. Para além disto, coligimos que ambos os modelos que obtêm melhor resultados para o conjunto de teste, uma vez que o índice de Jaccard e distância Euclidiana são superiores e inferiores para os mesmos, respetivamente. Deste modo, concluímos que estes mostraram ser robustos, ou seja, generalizaram de forma eficiente para dados com os quais não foram treinados. Note-se, no entanto, que o algoritmo que faz uso dos filtros morfológicos binários demonstrou uma performance consideravelmente superior e, assim, foram usadas as ROI obtidas por este, para além das GT ROI, aquando da segmentação de células na task seguinte.

3. Task 2, Trainset

A) Clustering

i) Ground-truth ROI Mask

Tabela (3): Resultados das métricas para a segmentação das células após aplicação de clustering e GT mask, para o train set

	Células Contadas	TP	FP	FN	Recall	Precision	F-measure
Média ± Desvio padrão	0,7 ± 6,973	0,1 ± 6,771	0,6 ± 0,904	3,78 ± 10,013	0,729 ± 0,329	0,859 ± 0,276	0,756 ± 0,322
Máximo	32	31	4	64	1	1	1

É possível constatar que os valores de recall, precision e F-measure são aceitáveis, uma vez que existe máximo igual a 1. No entanto, os resultados do set com este processamento e esta maks não são considerados satisfatórios. Isto pode ser corroborado pelo elevado desvio padrão de células contadas, quase dez vezes maior do que a média, pelo diminuto valor de média de true positives pelo elevado valor de false negatives.

ii) Task 1 ROI Mask

Tabela (4): Resultados das métricas para a segmentação das células, após aplicação de clustering e mask obtida da Task 1, para o trainset

	Células Contadas	TP	FP	FN	Recall	Precision	F-measure
Média ± Desvio padrão	7,18±8,40	6,48±8,16	0,70±1,49	5,08±7,45	0,592±0,386	0,813±0,317	0,635±0,368
Máximo	50	48	9	28	1	1	1

Analisando os resultados, a média de falsas positivas é reduzida, no entanto, a média de falsas negativas é ainda elevada, o que significa que muitas células não foram detetadas. Os valores médios de Recall, Precision e F-measure estão abaixo dos calculados para a GT mask, sendo o F-measure de 0,635, portanto, não muito elevado. Nesta perspetiva, a ROI determinada por filtros morfológicos demonstra piorar o desempenho da deteção de células. Assim, corrobora-se a ideia de que o Clustering, apesar de apresentar resultados medianos, não é o pré-processamento ideal neste trabalho.

B) Filtros morfológicos binários

i) Ground-truth ROI Mask

Tabela (5): Resultados das métricas para a segmentação das células, após aplicação de filtros morfológicos e GT mask, para o trainset

	Células Contadas	TP	FP	FN	Recall	Precision	F-measure
Média ± Desvio padrão	11,960 ± 10,17	11,320 ± 9,888	0,64 ± 0,776	0,96 ± 1,355	0,918 ± 0,110	0,930 ± 0,097	0,918 ± 0,082
Máximo	61	58	3	7	1	1	1

Como é possível observar na Tabela (3), a utilização de filtros morfológicos binários como pré-processamento e a Ground-truth ROI Mask para a segmentação das células e a sua contagem providencia valores de Recall, Precision e F-measure satisfatórios já que todos se encontram acima de 0,90. Estes valores, conjugados com os resultados do desvio padrão, indicam que, para o trainset, a maior parte das células foi corretamente segmentada em todas as imagens, havendo imagens onde a segmentação foi perfeita já que os valores máximos das métricas apresentadas acima correspondem a 1.

ii) Task 1 ROI Mask

Tabela (6): 1 Resultados das métricas para a segmentação das células, após aplicação de filtros morfológicos e mask obtida da Task 1, para o trainset

	Células Contadas	TP	FP	FN	Recall	Precision	F-measure
Média ± Desvio padrão	11,84±9,96	11,26±9,85	0,58±0,61	1,02±1,35	0,914±0,108	0,931±0,090	0,917±0,077
Máximo	60	58	2	7	1	1	1

Os valores médios obtidos para *Recall*, *Precision* e *F-measure* encontram-se acima de 0,9, pelo que se consideram elevados, enquanto os desvios rondam os 0,09, bastante baixos. Estes são semelhantes aos determinados com a GT mask. Adicionalmente, os valores máximos equivalentes a 1 indicam uma segmentação ideal para certas imagens. Portanto, é permitido concluir que os filtros morfológicos utilizados no pré-processamento resultam numa deteção eficaz das células, e a aplicação da ROI determinada por filtros morfológicos não prejudica os resultados.

4. Task 2, Testset

A) Clustering

i) Ground-truth ROI Mask

Tabela (7): Resultados das métricas para a segmentação das células após aplicação de clustering e GT mask, para o test set

	Células Contadas	TP	FP	FN	Recall	Precision	F-measure
Média ± Desvio padrão	11,96 ± 12,667	10,56 ± 11,218	1,4 ± 2,5	5,72 ± 11,134	0,711 ± 0,357	0,853 ± 0,245	0,724 ± 0,338
Máximo	42	37	10	41	1	1	1

Relativamente à utilização do *clustering* para processamento e da *Ground-truth mask* no *test set*, os valores de *recall*, *precision* e *F-measure* são semelhantes aos do mesmo tratamento no *train set*, com uma diminuição residual. O valor de células contadas, ao contrário do que acontecia no *train set*, são da mesma ordem de grandeza. Quanto à validade das células contadas, a média e os desvios também são da mesma ordem de grandeza, no entanto, quando se olha para os valores anteriores, de modo positivo, há mais *true positives*, no entanto também há um aumento no dobro de *false positives* e *false negatives*.

ii) Task 1 ROI Mask

Tabela (8): Resultados das métricas para a segmentação das células após aplicação de clustering e mask obtida da Task 1, para o test set

	Células Contadas	TP	FP	FN	Recall	Precision	F-measure
Média ± Desvio padrão	10,84 ± 12,61	9,84 ± 11,60	1,00 ± 1,55	5,88 ± 11,42	0,608 ± 0,390	0,794 ± 0,320	0,629 ± 0,372
Máximo	43	36	7	42	1	1	1

Ao contrário dos resultados apresentados na secção acima, ao usar o *clustering* como método de pré-processamento em imagens cuja região de interesse foi definida com filtros morfológicos, os valores médios das métricas calculadas encontram-se entre 0,60 e 0,80, sendo, portanto, significativamente inferiores ao desejado. Também os valores obtidos de desvio padrão são diferentes do expectável, desta vez por serem superiores, mostrando uma maior desconcordância entre as diferentes imagens. Por outro lado, os valores máximos das métricas em avaliação indicam que, em pelo menos uma das imagens, todas as células foram corretamente detetadas e segmentadas.

B) Filtros morfológicos binários

i) Ground-truth ROI Mask

Tabela (9): Resultados das métricas para a segmentação das células após aplicação de filtros morfológicos e GT mask, para o test set

	Células Contadas	TP	FP	FN	Recall	Precision	F-measure
Média ± Desvio padrão	17,040 ± 15,287	15,320 ± 13,363	1,72 ± 2,701	1,16 ± 1,519	0,929 ± 0,093	0,913 ± 0,098	0,915 ± 0,073
Máximo	46	39	10	6	1	1	1

Semelhantes aos valores obtidos para o *trainset*, os resultados de média de *Recall*, *Precision* e *F-measure* encontram-se acima de 0,90, sendo então avaliados como satisfatórios. Nesta instância, os valores de desvio padrão revelam-se menores, indicando uma maior concordância entre as diferentes imagens do *testset*. Quanto aos valores máximos, estes são todos iguais a 1, indicando que em certas imagens a segmentação é perfeita. Sendo assim, é passível afirmar-se que o algoritmo é capaz de se adaptar a dados desconhecidos, ou seja, diferentes do *trainset*.

ii) Task 1 ROI Mask

Tabela (10): Resultados das métricas para a segmentação das células após aplicação de filtros morfológicos e mask obtida da Task 1, para o test set

	Células Contadas	TP	FP	FN	Recall	Precision	F-measure
Média ± Desvio padrão	17,00 ± 15,26	15,28 ± 13,39	1,72 ± 2,64	1,2 ± 1,5	0,922 ± 0,093	0,912 ± 0,097	0,911 ± 0,071
Máximo	46	39	10	6	1	1	1

Na mesma linha do verificado para o *trainset*, os resultados de média de *Recall*, *Precision* e *F-measure* quando o pré-processamento e a delimitação da área de interesse das imagens são ambos feitos a partir de filtros morfológicos continuam, uma vez mais, a ultrapassar a marca dos 0,90, sendo, por isso, novamente classificados como satisfatórios. Relativamente aos valores de desvio padrão, estes foram reduzidos, o que revela a aplicabilidade vasta deste método. Por fim, o facto do valor máximo das 3 métricas ser 1, sugere que, em pelo menos uma

das imagens do *dataset* fornecido todas as células foram corretamente identificadas e segmentadas.

5. Comparação dos Métodos de Segmentação

De acordo com os resultados obtidos, podemos então concluir que, dos dois métodos de pré-processamento experimentados para prepararem a imagem a ser segmentada, filtros morfológicos binários e *clustering*, o primeiro alcançou melhores resultados, revelando métricas de avaliação com valores médios mais elevados e próximos do pretendido, assegurando que, entre os dois, é o método que identifica e conta células com mais precisão.




Figura 1 - segmentação após aplicação de GT mask e pré-processamento por *clustering*




Figura 2 - segmentação após aplicação de GT mask e pré-processamento por filtros morfológicos

V. CONCLUSÃO

Assim, as métricas calculadas permitem-nos considerar o sistema globalmente viável, mas ainda suscetível a melhoramentos, nomeadamente a minimização do número de células que ficam por identificar e segmentar com a proposta de algoritmo sugerida neste relatório. De um modo geral, podemos concluir que a melhor opção encontrada para a solução do problema apresentado no início deste relatório envolve usar filtros morfológicos binários tanto para delimitar a região de interesse de cada imagem, como para a pré-processar, antes de ser submetida ao processamento de deteção de círculos e criação das *bounding boxes*.

VI. REFERÊNCIAS

- [1] Özkan, A., İşgör, S. B., Şengül, G., & İşgör, Y. G. (2018). Computer vision based automated cell counting pipeline: A case study for HL60 cancer cell on hemocytometer. *Biomedical Research*, 29(14), 2956-2962.